

Erklärung des verwendeten Algorithmus zur optimalen Regelbestimmung

Setting. Datensatz mit n Zeilen, m binären Prädikaten $p_1, \dots, p_m$ (z. B. eq_start_date, overlap_0.5_TAB_BETR_POSITION) und Label $y \in \{0, 1\}^n$. Eine **AND-Regel** ist eine Konjunktion $R = p_{i_1} \wedge \dots \wedge p_{i_\ell}$, $\ell \leq k$.

Ziel. Finde eine **Composition** $C = R_1 \vee R_2 \vee \dots \vee R_r$ aus r AND-Regeln, sodass $\text{Precision}(C)$ maximiert wird unter der Nebenbedingung $\text{Recall}(C) \geq \rho^*$.

Phase 1 — Kandidatengenerierung (Apriori). Aus den $\sum_{\ell=1}^k \binom{m}{\ell}$ möglichen AND-Regeln werden zwei Klassen entfernt:

- ▶ **Subset-Prädikate derselben Familie** ($\text{dist}_1 \subset \text{dist}_2$, $\text{prop}_{0.99} \subset \text{prop}_{0.95}$, ...): pro Feature-Gruppe nur eines.
- ▶ **Anti-monotones TP-Pruning:** Regeln mit $TP(R) < \min_new_tp$ verwerfen, da $TP(R \wedge p) \leq TP(R)$.

Ergebnis: Kandidatenmenge $\mathcal{R} = \{(R_i, m_i)\}_{i=1}^{|\mathcal{R}|}$ mit Maskenvektoren $m_i \in \{0, 1\}^n$, $(m_i)_j = 1 \Leftrightarrow R_i$ feuert auf Zeile j .

Phase 2 — Greedy-Selektion. Sei $c^{(t)} = \bigvee_{u \leq t} m_{s_u}$ der OR-Vektor nach Schritt t , $tp^{(t)} = 1^\top (c^{(t)} \wedge y)$, $pos^{(t)} = 1^\top c^{(t)}$, $\Delta tp_i = 1^\top (m_i \wedge \neg c^{(t-1)} \wedge y)$, $\Delta pos_i = 1^\top (m_i \wedge \neg c^{(t-1)})$. In jedem Schritt wird die Regel hinzugefügt, welche die Precision der *gesamten* Composition maximiert:

$$s_t = \arg \max_{i \in \mathcal{A}^{(t)}} \frac{tp^{(t-1)} + \Delta tp_i}{pos^{(t-1)} + \Delta pos_i} \quad \text{u. d. N.} \quad \Delta tp_i \geq \min_new_tp$$

Abbruch bei $tp^{(t)} / \text{total_pos} \geq \rho^*$ oder leerer Alive-Menge $\mathcal{A}^{(t)}$.

Nachverarbeitung. Reduziert die Regelanzahl ohne (Subsumption, Unique-TP) bzw. mit kontrolliertem Recall-Verlust (Merge).

Subsumption

Lockerheitshierarchie pro Feature-Familie, z. B. eq $\subset$ dist_1 $\subset \dots \subset$ dist_4. Schreibe $\ell(p)$ für den Lockerheitsindex. A *dominiert* B ($A \succ B$) gdw. $\forall p_A \in A \exists p_B \in B$ derselben Gruppe mit $\ell(p_A) \geq \ell(p_B)$. Dann $m_B \subseteq m_A$, also B redundant in $A \vee B$.

Unique True Positives

Für $R_i \in \{R_1, \dots, R_r\}$:

$$UTP(R_i) = 1^\top \left(m_i \wedge \bigwedge_{j \neq i} \neg m_j \wedge y \right).$$